

Jigsaw Toxic Comment Classification Challenge - 實驗專案報告

課程：高中人工智慧應用與實作期末成果 | 模型架構：TF-IDF+LR / DistilBERT / Ensemble

1. 資料探索與不平衡處理 (DATA EXPLORATION & IMBALANCE)

本專案使用 Jigsaw 惡意留言資料集，包含約 16 萬筆已標記訓練資料與 15 萬筆未標記測試資料。任務屬多標籤分類 (Multi-label Classification)，目標為預測留言屬於 6 個非互斥惡意類別 (Toxic, Severe Toxic, Obscene, Threat, Insult, Identity Hate) 的機率。

類別不平衡問題：經統計，無毒留言佔總資料之 89.8%，而惡意標籤比例極度不均。其中最嚴重的為 **Threat (0.3%)** 與 **Identity Hate (0.9%)**。為防止模型忽視稀有標籤，本專案在傳統模型調校中提高正樣本懲罰權重，並在 Transformer 微調中使用二元交叉熵損失 (BCEWithLogitsLoss) 對 6 個標籤獨立計算，透過 W&B 監控 Mean AUC，確保模型在稀有類別上的敏感度。

2. 模型架構與實驗設計 (METHODOLOGY & TRAINING SETUP)

- Baseline 模型：**採用統計學特徵工程，利用 TF-IDF 抽取前 30,000 個高頻詞與雙詞組 (n-gram range 1-2)，排除英文停用詞 (Stop Words)。後端串接 6 個獨立的邏輯迴歸 (Logistic Regression) 模型，設定超參數 **C=4.0**，優化器採 **liblinear**。
- Transformer 微調模型：**載入預訓練通用編碼器 **DistilBERT** ('distilbert-base-uncased')。隨機初始化末端分類頭 (Classification Head)，輸出維度為 6。設定文字最大長度 **max_len=192**、Batch Size=32、訓練 1 個 Epoch、Warmup Steps=500、學習率權重衰減 0.01，啟用 Mixed Precision (fp16) 加速。
- 模型融合 (Ensemble) 策略：**結合兩者優勢進行軟投票融合 (Soft Voting)，公式為：

$$P_{final} = 0.1 \times P_{Baseline} + 0.9 \times P_{Transformer}$$

3. 實驗數據與消融實驗 (QUANTITATIVE RESULTS & ABLATION STUDY)

所有模型均採 10% 獨立驗證集評估，並將預測結果提交至 Kaggle 進行 Late Leaderboard 評分，官方評估指標為 6 個標籤的平均 ROC-AUC (Mean AUC)。

模型版本 / 實驗設定	驗證集 Mean AUC	Kaggle Leaderboard (Private)	訓練耗時 / 資源說明
Baseline (TF-IDF + LR)	0.9710	0.9717	~15 秒 (CPU)
Transformer (DistilBERT V7 - MaxLen 192)	0.9912	0.9854	~26 分鐘 (Kaggle GPU T4 x2)
消融實驗 (DistilBERT V8 - MaxLen 128)	0.9868	0.9811	~18 分鐘 (Kaggle GPU T4 x2)
Ensemble (0.1*LR + 0.9*DistilBERT V7)	0.9925	0.9882	模型加權融合 (賺取加分題)

消融實驗分析 (Ablation Study)：為符合 W&B 實驗追蹤要求，專案執行了「縮短文本截斷長度 (**max_len**)」的消融實驗。將長度由 192 降至 128 時，由於矩陣運算量減少，訓練時間大幅縮短了 30.7% (由 26 分鐘降至 18 分鐘)。然而，此舉導致長留言後段的關鍵惡意詞彙被強制截斷，使驗證集 Mean AUC 從 0.9912 下滑至 0.9868，Kaggle 私人榜分數亦跌落至 0.9811。實驗證明，192 的上下文窗口對於捕捉長篇戰文中的毒性至關重要。

4. 錯誤分析：AI 猜錯的具體案例 (ERROR ANALYSIS)

透過分析驗證集中「人類真實標籤 (Ground Truth)」與「模型預測機率」的落差，篩選出 5 個最具代表性的誤判案例，歸納出兩大核心錯誤模式：

案例一：反諷與高級酸 (Sarcasm & Passive Aggressive) **False Positive (偽陽性)**

留言："Oh great, another brilliant edit by our resident expert. You clearly know everything about history."

分析：字面上全為正向詞彙 (brilliant, expert, know everything)，但實際為反諷。傳統模型完全漏判；而 Transformer 模型由於在網路語料中學過這類語境，給出了較高的 Toxic 評分，但因缺乏上下文明確衝突，被判定為有毒，屬於「過度敏感」造成的偽陽性。

案例二：引述違規言論或學術討論 (Quoting Abuse / Academic Context) False Positive (偽陽性)

留言："The word 'nigger' originates from the Spanish word negro. It has been used as a racial slur."

分析：留言中包含了極度敏感的種族仇恨詞彙。TF-IDF 基準模型因「袋詞 (Bag-of-Words)」機制，看到該詞便直接判定為 **Identity Hate (Prob>0.9)**。DistilBERT 雖然機率較低，但依然將其誤判為有毒。模型無法有效區分「惡意攻擊他人」與「客觀探討/舉報詞彙歷史」的動機差異。

案例三：隱蔽式威脅與隱喻 (Implicit Threat & Metaphor) False Negative (偽陰性)

留言："I know where you live, buddy. Let's see if you can still edit Wikipedia tomorrow."

分析：此句沒有任何髒話或暴利字眼。Baseline 模型給出的 **Threat** 機率近乎於 0（完全遺漏）。DistilBERT 雖捕捉到威脅語意，但預測機率僅 0.53，在嚴格的門檻下易被歸類為無毒。這種缺乏表面特徵、高度依賴社會常識理解的隱蔽威脅，是當前 AI 的主要盲點。

案例四：特定社群網路俚語 (Community Slang & Dogwhistles) False Negative (偽陰性)

留言："You are such a fragile snowflake, go back to your safe space before you cry."

分析："snowflake" 與 "safe space" 屬於現代社群網路的政治衍生諷刺語。傳統 TF-IDF 將其視為普通物理詞彙（雪花、安全空間）而完全略過。Transformer 對此具備較佳的表徵能力，但仍低估了其對特定群體致使的心理精神傷害（**Insult** 預測機率偏低）。

案例五：極端情緒但非惡意發洩 (Intense Venting without Malice) False Positive (偽陽性)

留言："This development pipeline is a fucking nightmare! I hate this broken code so much!"

分析：留言包含 "fucking" 與 "hate"，使兩個模型在 **Obscene** 與 **Toxic** 上的分數皆破表。然而人類標籤判定此為對事物的「情緒宣洩」，並非「針對特定人身進行惡意攻擊」。模型目前依然缺乏「對事不對人」的語境分析能力。

5. 綜合討論與結論 (DISCUSSION & CONCLUSION)

Transformer 捕捉到什麼？ 傳統 TF-IDF + 邏輯迴歸模型僅能進行單詞特徵統計，一旦遇到缺乏髒話的「隱蔽威脅」或「網路俚語（如案例三、四）」，其袋詞機制便完全失效。而 DistilBERT 透過多頭自注意力機制 (Multi-Head Self-Attention)，能成功建立字詞間的長距離依賴關係，敏銳地捕捉到字面背後隱含的敵意與脈絡，因而在群體仇恨與威脅等高難度稀有標籤上，AUC 表現大幅領先。

模型的殘留盲點： 儘管 Transformer 實力強大，但在「反諷（案例一）」、「學術學術探討（案例二）」及「非人身的情緒宣洩（案例五）」上依然頻繁翻車。這揭示了當前大型語言模型在面對複雜人類動機、常識推論及言外之意 (Pragmatics) 時的局限性。

結論： 本專案最終透過「模型融合 (Ensemble)」，成功結合了傳統模型在字串匹配上的高準確度與 Transformer 在語意理解上的高召回率，在 Kaggle Leaderboard 斬獲 **0.9882** 的優異成績（超越單一模型與作業 0.985 的滿分高標），圓滿達成專案任務。